

范畴论视角的深度学习：Para 构造与 Lens 范畴

摘要

在深度学习的理论奠基中，我们需要一种数学工具，既能描述数据的双向流动（前向传播计算预测值，反向传播计算梯度），又能刻画神经网络中权重参数的独立存在与更新。应用范畴论（Applied Category Theory）给出了极为优雅的答案：**Lens 范畴**用于处理双向数据流，而 **Para 构造**用于处理带参数的映射。现代深度学习架构本质上就是 **Para(Lens(Smooth))** 范畴中的态射（Morphisms）的复合。本文将把所有前置定义集中于此，并通过一个不平凡例子——带有非线性激活函数的全连接层（Dense Layer）——来详细演示深度学习中的反向传播是如何通过范畴论严格对应的。

1 核心数学定义

为了严谨，我们首先设定底范畴（Base Category）为 **Smooth**，即对象为欧几里得空间 $\mathbb{R}^n$ ，态射为它们之间的光滑函数（Smooth Functions）。这是一个带有标准笛卡尔乘积 $\times$ 的对称幺半范畴（Symmetric Monoidal Category）。

1.1 Lens 范畴（The Lens Category）

Lens 范畴通常用于刻画具有“前向状态”和“后向反馈”的系统。在深度学习的上下文中，我们将对象定义为一对空间 (A, dA) ，其中 A 是前向激活值的空间， dA 是对应梯度的空间（在 **Smooth** 中，它们同构，即 $A \cong dA \cong \mathbb{R}^n$ ）。

定义 1.1. 在 **Lens(Smooth)** 中，从对象 A 到对象 B 的一个态射（Lens），记作 $f : A \rightarrow B$ ，由一对光滑函数 (f_1, f_2) 组成：

1. 前向映射（Forward pass）： $f_1 : A \rightarrow B$
2. 反向映射（Backward pass）： $f_2 : A \times dB \rightarrow dA$

注记 1.1. 直观理解：前向映射利用输入 $a \in A$ 计算输出 $b \in B$ ；反向映射则利用原始输入 $a \in A$ 以及从后方传来的关于输出的误差（梯度） $db \in dB$ ，计算出关于输入的误差（梯度） $da \in dA$ 。

定义 1.2 (Lens 的复合 (Chain Rule)). 给定 $f : A \rightarrow B$ 和 $g : B \rightarrow C$ ，它们的复合 $g \circ f : A \rightarrow C$ 定义为：

- 前向： $(g \circ f)_1(a) = g_1(f_1(a))$
- 反向： $(g \circ f)_2(a, dc) = f_2(a, g_2(f_1(a), dc))$

1.2 Para 构造 (The Para Construction)

纯粹的 Lens 只能描述固定的双向计算。神经网络需要”被参数化”的映射（即权重和偏置）。给定一个对称幺半范畴 $\mathcal{C}$ ，Para 构造可以将它转化为一个新的范畴 $\mathbf{Para}(\mathcal{C})$ 。

定义 1.3. 在 $\mathbf{Para}(\mathcal{C})$ 中，对象与底范畴 $\mathcal{C}$ 相同。从对象 A 到对象 B 的态射是一个等价类 (P, f) ，其中：

1. 参数空间: $P \in \text{Ob}(\mathcal{C})$
2. 参数化映射: $f : P \times A \rightarrow B$ 属于 $\mathcal{C}$ 中的态射。

定义 1.4 (Para 的复合). 给定 $(P, f) : A \rightarrow B$ 与 $(Q, g) : B \rightarrow C$ ，它们的复合是一个以 $Q \times P$ 为参数空间的新态射 $(Q \times P, h) : A \rightarrow C$ ，其中前向映射为：

$$h(q, p, a) = g(q, f(p, a))$$

1.3 终极综合：Para(Lens)

当我们把 Para 作用于 Lens，我们就得到了深度学习的数学骨架。在 $\mathbf{Para}(\mathbf{Lens})$ 中，一个参数为 P 的态射 $f : A \rightarrow B$ ，实际上是一个 Lens $f : P \times A \rightarrow B$ 。展开来说，它包含：

1. 参数化前向: $f_1 : P \times A \rightarrow B$ （给定参数和输入，计算输出）
2. 参数化反向: $f_2 : (P \times A) \times dB \rightarrow dP \times dA$ （给定参数、输入以及输出的梯度，同时计算出参数的梯度 dP 和输入的梯度 dA ）。

2 不平凡的教学示例：带激活函数的全连接层

为了展示这套理论的威力，我们不仅要看一个简单的线性映射，还要看它的复合与非线性激活。

目标：用 $\mathbf{Para}(\mathbf{Lens})$ 严谨刻画一个前馈神经网络层 $y = \sigma(Wx + b)$ ，其中 $x \in \mathbb{R}^n$ 是输入， $W \in \mathbb{R}^{m \times n}$ 是权重矩阵， $b \in \mathbb{R}^m$ 是偏置向量， σ 是逐元素的非线性激活函数（例如 Sigmoid 或 ReLU）， $y \in \mathbb{R}^m$ 是输出。

这个层可以分解为三个独立态射的复合：线性映射、偏置加法、非线性激活。

2.1 态射 1：线性变换 (Linear Transformation)

- 对象映射: $\mathbb{R}^n \rightarrow \mathbb{R}^m$
- 参数空间: $P_W = \mathbb{R}^{m \times n}$ （矩阵空间）

- 前向映射 L_1 :

$$L_1(W, x) = Wx$$

- 反向映射 L_2 : 接收 (W, x) 和输出误差 $dy \in \mathbb{R}^m$, 输出 (dW, dx) 。根据微积分, 我们有:

$$L_2(W, x, dy) = (dy \cdot x^T, W^T dy)$$

注记 2.1. $dy \cdot x^T$ 对应权重的梯度 dW , $W^T dy$ 对应向后传递的输入梯度 dx 。

2.2 态射 2: 偏置加法 (Bias Addition)

- 对象映射: $\mathbb{R}^m \rightarrow \mathbb{R}^m$
- 参数空间: $P_b = \mathbb{R}^m$
- 前向映射 B_1 :

$$B_1(b, z) = z + b$$

- 反向映射 B_2 : 接收 (b, z) 和输出误差 $dy \in \mathbb{R}^m$, 输出 (db, dz) :

$$B_2(b, z, dy) = (dy, dy)$$

注记 2.2. 加法的雅可比矩阵是单位阵, 所以误差原样传递。偏置梯度就是 dy , 输入梯度也是 dy 。

2.3 态射 3: 非线性激活 (Non-linear Activation)

- 对象映射: $\mathbb{R}^m \rightarrow \mathbb{R}^m$
- 参数空间: $\mathbf{1}$ (或者说参数空间为空/零维, 因为激活函数没有可训练参数, 这是一个无参数的 Lens)。
- 前向映射 Σ_1 :

$$\Sigma_1(*, u) = \sigma(u)$$

- 反向映射 Σ_2 :

$$\Sigma_2(*, u, dy) = (0, dy \odot \sigma'(u))$$

注记 2.3. $\odot$ 为 Hadamard 乘积, 即逐元素相乘。不需要更新参数所以梯度为 0。

3 态射的复合与反向传播的自动推导

现在，我们将这三个态射在 **Para(Lens)** 中复合： $\text{Layer} = \Sigma \circ B \circ L$ 。

复合态射 $\text{Layer} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ 的参数空间是各态射参数空间的乘积： $P = \mathbf{1} \times P_b \times P_W \cong \mathbb{R}^m \times \mathbb{R}^{m \times n}$ 。

3.1 复合的前向传播 (Forward Pass)

根据 Para 范畴的复合规则：

$$\text{Layer}_1((b, W), x) = \Sigma_1(*, B_1(b, L_1(W, x)))$$

逐步代入：

- $z_1 = L_1(W, x) = Wx$
- $z_2 = B_1(b, z_1) = Wx + b$
- $y = \Sigma_1(*, z_2) = \sigma(Wx + b)$

这完美地给出了深度学习前向推断的数学表达式。

3.2 复合的反向传播 (Backward Pass)

这是 Lens 范畴复合规则的精髓所在。给定最终的输出梯度 dy_{out} ，我们需要回溯。根据 Lens 的复合公式 $(g \circ f)_2(a, dc) = f_2(a, g_2(f_1(a), dc))$ ，这相当于逆序执行反向映射并解构状态。

Step A (过激活层)：

$$(d*, dz_2) = \Sigma_2(*, z_2, dy_{\text{out}}) = (0, dy_{\text{out}} \odot \sigma'(Wx + b))$$

此时我们得到了流入前一层的误差 $dz_2 = dy_{\text{out}} \odot \sigma'(Wx + b)$ 。

Step B (过偏置层)：

$$(db, dz_1) = B_2(b, z_1, dz_2) = (dz_2, dz_2)$$

此时我们得到了偏置参数的更新梯度： $db = dy_{\text{out}} \odot \sigma'(Wx + b)$ ，以及继续向前传递的误差 $dz_1 = dz_2$ 。

Step C (过线性层)：

$$(dW, dx) = L_2(W, x, dz_1) = (dz_1 \cdot x^T, W^T dz_1)$$

此时我们得到了权重矩阵的更新梯度： $dW = (dy_{\text{out}} \odot \sigma'(Wx + b)) \cdot x^T$ ，以及最终传递给网络上一层的输入梯度： $dx = W^T(dy_{\text{out}} \odot \sigma'(Wx + b))$ 。

4 教学总结与严谨对应

通过上述推导，我们可以总结出以下严谨的对应关系（Mapping）：

深度学习概念	范畴论结构	备注细节
网络层级的数据类型	底范畴的对象 $\text{Ob}(\mathcal{C})$	如欧几里得空间 $\mathbb{R}^n, \mathbb{R}^m$ 。
前向预测与反向求导机制	Lens 范畴	提供了一对态射 (f_1, f_2) ， f_2 依赖 f_1 的状态。
层内的可训练权重（Weights, Biases）	Para 构造的参数对象 $P \in \text{Ob}(\mathcal{C})$	将纯函数提升为参数化函数集。
一个带参数的网络层	$\text{Para}(\text{Lens})$ 中的一个态射	输入和输出皆包含数据与梯度双重属性。
构建深度网络（如 Sequential）	范畴中的态射复合	$(P, f) \circ (Q, g) \rightarrow (Q \times P, h)$ 。

教学核心结论：

在传统微积分教学中，反向传播（Backpropagation）通常是用大量的求导符号、下标和展开图来”手算”出来的，这在网络层级变深、尤其是遇到非树状计算图时会显得极其杂乱。

而通过 **Para** 和 **Lens**，我们将深度学习网络完全代数化、结构化。一个庞大的深度神经网络，不过是 **Para(Lens(Smooth))** 范畴中的多个小态射（如基础操作算子）通过 $\circ$ 符号严格连接而成的单一复合态射。PyTorch 和 JAX 的 Autograd 引擎（尤其是带有显式参数状态追踪的 JAX，其 `vjp` 就是 Lens 范畴完美的程序实现），在底层架构上恰恰遵循了这一范畴论规律。