

Lens(Smooth) 范畴论与几何深度学习基础

生成时间：2026 年 6 月 28 日 16:15

目录

1	引言	2
2	几何直觉与核心澄清	2
2.1	梯度的逐点依赖性——为什么需要引入纤维丛？	2
2.2	“内积”与“对偶配对”的严格区分	2
2.3	推前 (Pushforward) 与拉回 (Pullback)	3
2.3.1	推前 (Pushforward)	3
2.3.2	拉回 (Pullback)	3
3	Lens(Smooth) 的严谨定义	3
3.1	对象 (Objects)	3
3.2	态射 (Morphisms)	3
3.2.1	前向映射 (Forward Pass)	4
3.2.2	反向映射 (Backward Pass)	4
4	证明 Lens(Smooth) 满足范畴公理	4
4.1	恒等态射 (Identity Morphism)	4
4.2	态射的复合 (Composition)	4
4.2.1	前向复合	5
4.2.2	反向复合 (核心链式法则)	5
4.3	公理验证一：结合律 (Associativity)	5
4.3.1	前向结合律	5
4.3.2	反向结合律	5
4.4	公理验证二：单位律 (Identity Laws)	6
4.4.1	右单位律 $f \circ \text{id}_M = f$	6
4.4.2	左单位律 $\text{id}_N \circ f = f$	6

1 引言

在传统的深度学习框架中，神经网络的前向传播与反向传播往往被视为工程上的数组操作。然而，当我们将视角提升到微分几何与范畴论的高度时，神经网络的运行机制展现出了极其优美的代数与几何对称性。

本文档旨在严谨地构造光滑流形上的透镜范畴 **Lens(Smooth)**，并彻底厘清在这个框架下，状态、梯度、推前 (Pushforward)、拉回 (Pullback) 以及对偶配对之间的严格数学关系。

2 几何直觉与核心澄清

在进入范畴的严格定义前，我们必须首先清除在平坦空间（如 $\mathbb{R}^n$ ）中由于过度简化而产生的数学错觉，并回答关于“点”、“内积”和“拉回”的核心疑问。

2.1 梯度的逐点依赖性——为什么需要引入纤维丛？

之前的错觉：假设前向状态空间 A 和梯度空间 dA 是分离且全局同构的（即 $A \cong dA \cong \mathbb{R}^n$ ）。**几何真相：**在一般的光滑流形（如曲面）上，空间是弯曲的。梯度（属于余切空间）绝对不能脱离它所在的“点”而独立存在。

- 流形 M ：**所有可能的前向状态点的集合。
- 余切空间 T_x^*M ：**依附于特定点 $x \in M$ 上的局部空间，专门用来容纳在该点计算出的梯度。
- 余切丛 T^*M ：**流形上所有点及其对应的余切空间的无交并，即

$$T^*M = \bigcup_{x \in M} (\{x\} \times T_x^*M).$$

核心结论：任何一个梯度数据必须是一个对偶 (x, dx) ，其中 x 锚定了你在流形上的位置， $dx \in T_x^*M$ 是该位置的局部梯度。

2.2 “内积”与“对偶配对”的严格区分

你的疑问：内积可以是切空间和余切空间做内积吗？**严格澄清：**绝对不可以。内积只能发生在同一个空间内部（例如两个切向量之间）。我们在反向传播中看到的符号 $\langle \cdot, \cdot \rangle$ ，其真实身份是**对偶配对 (Dual Pairing)**。

- 切向量 $v \in T_x M$ ：**代表在点 x 处的“运动速度”或“微小扰动”。
- 余切向量 $dx \in T_x^* M$ ：**代表一个“测速仪”或“线性泛函”（函数）。

- 对偶配对 $\langle dx, v \rangle$: 本质上是函数的调用, 即 $dx(v)$ 。它表示将扰动 v 喂给测度仪 dx , 计算出一个标量 (实数 $\mathbb{R}$), 代表该扰动导致的整体 Loss 变化率。

2.3 推前 (Pushforward) 与拉回 (Pullback)

设有一个平滑映射 $f : M \rightarrow N$ 。

2.3.1 推前 (Pushforward)

推前 $d(f)_x : T_x M \rightarrow T_{f(x)} N$ 是前向映射在点 x 处的局部线性化 (雅可比矩阵)。它顺着函数的方向, 将输入空间的速度推到输出空间。

2.3.2 拉回 (Pullback)

拉回 $(d(f)_x)^* : T_{f(x)}^* N \rightarrow T_x^* M$ 是推前的伴随映射 (Adjoint Map)。它逆着函数的方向, 将输出端的误差梯度拉回到输入端。

拉回的终极无坐标定义: 拉回算子 $(d(f)_x)^*$ 的定义, 完全依赖于对偶配对的守恒律 (即多变量微积分的链式法则本身):

$$\langle (d(f)_x)^*(dy), v \rangle = \langle dy, d(f)_x(v) \rangle$$

(左侧发生在输入空间 M 中, 右侧发生在输出空间 N 中。通过要求两端变化率一致, 严谨地构造出了输入端的梯度。)

3 Lens(Smooth) 的严谨定义

现在, 我们使用范畴论的语言, 将上述几何过程封装为 **Lens(Smooth)** 范畴。

3.1 对象 (Objects)

Lens(Smooth) 中的对象就是光滑流形 (Smooth Manifolds)。设 M, N 为光滑流形。

(注: 在依赖透镜的语境下, 对象 M 隐式地携带了它的余切丛 T^*M 作为反向传播的空间。)

3.2 态射 (Morphisms)

一个态射 (Lens) $f : M \rightarrow N$ 是一对平滑映射 (f_1, f_2) , 其中:

3.2.1 前向映射 (Forward Pass)

$$f_1 : M \rightarrow N$$

表示系统状态从流形 M 转换到流形 N 。

3.2.2 反向映射 (Backward Pass)

$$f_2 : M \times_N T^*N \rightarrow T^*M$$

- **定义域解析：**符号 $M \times_N T^*N$ 表示拉回丛 (Pullback Bundle)。其元素是对偶 (x, dy) ，必须满足严格的对齐约束： $x \in M$ ，且 $dy \in T^*_{f_1(x)}N$ 。这在数学上保证了反向传播时，接收到的梯度必定属于前向输出点所在的局部余切空间。
- **值域解析：**输出必定属于起点 x 的余切空间，即 $f_2(x, dy) \in T^*_xM$ 。

自动微分函子 (特例)：在深度学习的自动微分中，反向映射 f_2 被严格取值为雅可比的拉回，即

$$f_2(x, dy) = (d(f_1)_x)^*(dy).$$

但在更一般的 **Lens** 范畴定义中， f_2 可以是任何在纤维上保持线性的平滑映射（这允许我们定义自定义的、非精确的梯度更新策略）。

4 证明 Lens(Smooth) 满足范畴公理

为了证明 **Lens(Smooth)** 确实是一个范畴，我们必须定义态射的恒等元 (Identity) 和复合运算 (Composition)，并证明其满足结合律 (Associativity) 和单位律 (Identity Laws)。

4.1 恒等态射 (Identity Morphism)

对于任意对象 M ，定义恒等态射 $\text{id}_M = ((\text{id}_M)_1, (\text{id}_M)_2) : M \rightarrow M$ 如下：

$$(\text{id}_M)_1(x) = x, \quad (\text{状态不变})$$

$$(\text{id}_M)_2(x, dx) = dx. \quad (\text{梯度原样传回})$$

4.2 态射的复合 (Composition)

设有两个连续的网络层 (态射)：

$$f = (f_1, f_2) : M \rightarrow N, \quad g = (g_1, g_2) : N \rightarrow K.$$

它们的复合 $h = g \circ f : M \rightarrow K$ 定义为 $h = (h_1, h_2)$ ：

4.2.1 前向复合

$$h_1(x) = g_1(f_1(x)).$$

4.2.2 反向复合（核心链式法则）

给定 $x \in M$ 以及 $dk \in T_{h_1(x)}^*K$ ，反向复合定义为：

$$h_2(x, dk) = f_2\left(x, g_2(f_1(x), dk)\right).$$

（直观理解：先将最末端的梯度 dk ，连同中间状态 $f_1(x)$ 喂给 g_2 ，算出中间梯度；再将这个中间梯度，连同初始状态 x 喂给 f_2 ，算出最终梯度。）

4.3 公理验证一：结合律（Associativity）

设 $f : M \rightarrow N, g : N \rightarrow K, w : K \rightarrow L$ 。我们需要证明

$$(w \circ g) \circ f = w \circ (g \circ f).$$

4.3.1 前向结合律

由于流形间的映射复合满足结合律，显然有：

$$((w \circ g) \circ f)_1(x) = w_1(g_1(f_1(x))) = (w \circ (g \circ f))_1(x).$$

4.3.2 反向结合律

令末端误差为 $dl \in T^*L$ 。

步骤一：左侧 $((w \circ g) \circ f)_2$ 展开：

$$\begin{aligned} ((w \circ g) \circ f)_2(x, dl) &= f_2\left(x, (w \circ g)_2(f_1(x), dl)\right) \\ &= f_2\left(x, g_2(f_1(x), w_2(g_1(f_1(x)), dl))\right). \end{aligned}$$

步骤二：右侧 $(w \circ (g \circ f))_2$ 展开：

$$\begin{aligned} (w \circ (g \circ f))_2(x, dl) &= (g \circ f)_2\left(x, w_2((g \circ f)_1(x), dl)\right) \\ &= (g \circ f)_2\left(x, w_2(g_1(f_1(x)), dl)\right) \\ &= f_2\left(x, g_2(f_1(x), w_2(g_1(f_1(x)), dl))\right). \end{aligned}$$

左右两边完全相等，结合律成立。

□

4.4 公理验证二：单位律 (Identity Laws)

我们需要证明对于 $f : M \rightarrow N$ ，有

$$f \circ \text{id}_M = f \quad \text{且} \quad \text{id}_N \circ f = f.$$

4.4.1 右单位律 $f \circ \text{id}_M = f$

前向：

$$(f \circ \text{id}_M)_1(x) = f_1((\text{id}_M)_1(x)) = f_1(x).$$

反向：

$$\begin{aligned} (f \circ \text{id}_M)_2(x, dy) &= (\text{id}_M)_2(x, f_2((\text{id}_M)_1(x), dy)) \\ &= (\text{id}_M)_2(x, f_2(x, dy)) \\ &= f_2(x, dy). \end{aligned}$$

所以 $f \circ \text{id}_M = f$ 。 □

4.4.2 左单位律 $\text{id}_N \circ f = f$

前向：

$$(\text{id}_N \circ f)_1(x) = (\text{id}_N)_1(f_1(x)) = f_1(x).$$

反向：

$$\begin{aligned} (\text{id}_N \circ f)_2(x, dy) &= f_2(x, (\text{id}_N)_2(f_1(x), dy)) \\ &= f_2(x, dy). \end{aligned}$$

所以 $\text{id}_N \circ f = f$ 。 □

结论：带有纤维配对约束的 **Lens(Smooth)** 严格满足范畴论的所有公理，构成一个合法的范畴。

5 结语

通过 **Lens(Smooth)**，我们不再把深度学习视为一堆经验性的矩阵相乘，而是将其确立为光滑流形范畴之上的函子与态射操作。结合 **Para** 构造（将参数空间以张量积的形式挂载到 **Lens** 上），现代深度学习框架的底层结构在纯数学中找到了最严密、最优美的倒影。
